

Mon Projet Data Science

Projet Fil Rouge Data Science - Sujet Libre

Étudiant(e) 1 : [Insérer Prénom Étudiant(e) 2 : [Insérer Prénom Étudiant(e) 3 : [Insérer Prénom
Nom] Nom] Nom]

2026-05-18

Table of contents

1	Introduction et Contexte Métier	2
1.1	Contexte du Projet	2
1.2	Objectif Analytique	3
2	Acquisition et Préparation des Données (Data Wrangling)	3
2.1	Audit de Qualité	3
2.2	Algorithme de Nettoyage	3
2.3	Travaux Pratiques de Wrangling	3
3	01 — Acquisition, compréhension et préparation des données	3
3.1	Objectif du notebook	3
3.2	Structure du dataset	4
3.3	Chargement des activités	4
3.4	Chargement des variables	4
3.5	Reconstruction des jeux train et test	4
3.6	Vérifications qualité	4
3.7	Sauvegarde des données tabulaires propres	4
3.8	Préparation des signaux inertiels	4
3.9	Conclusion du wrangling	5
4	Analyse Exploratoire des Données (EDA)	5
4.1	Statistiques Descriptives	5
4.2	Ingénierie de Variables (Feature Engineering)	5
4.3	Travaux Pratiques d'Exploration Visuelle (EDA)	5
5	☒ Jalon 1 : Analyse Exploratoire des Données (EDA) & Visualisation (Squelette Étudiant)	5
5.0.a	1. Importation des packages et configuration du style	5
5.0.b	2. Ingénierie de variables temporelles	5
5.0.c	3. Visualisations Professionnelles	6
5.0.d	4. Synthèse des observations clés	6
6	Visualisation Multidimensionnelle (Insights)	6
6.1	Profils et Distributions Caractéristiques	6

6.2	Corrélations Globales	6
7	Modélisation et Apprentissage	7
7.1	Schéma Global du Pipeline de Données	7
7.2	Modélisation Tabulaire (Machine Learning)	7
7.2.a	Travaux Pratiques de Modélisation Tabulaire	7
8	 Jalon 2 : Modélisation Prédicative & Apprentissage (Squelette Étudiant)	7
8.0.a	1. Préparation de l'environnement	8
8.0.b	2. Définition des variables et split chronologique	8
8.0.c	3. Entraînement du modèle de Forêt Aléatoire	8
8.0.d	4. Évaluation métrique	8
8.0.e	5. Importance des variables explicatives	8
8.1	Modélisation Vision / Deep Learning (Analyse d'Images ou Signaux)	8
8.1.a	Travaux Pratiques de Vision par Ordinateur (CNN)	8
9	 Jalon 2 : Brique de Vision par Ordinateur (CNN & TensorFlow) (Squelette Étudiant)	8
9.0.a	1. Préparation de l'environnement	8
9.0.b	2. Génération du jeu d'images synthétiques	8
9.0.c	3. Split d'évaluation (Entraînement / Validation)	8
9.0.d	4. Conception de l'architecture du CNN	9
9.0.e	5. Compilation et Entraînement	9
10	Évaluation Métrique et Validation	9
10.1	Stratégie de Validation	9
10.2	Résultats et Interprétation	9
11	Data Storytelling et Communication	9
11.1	Recommandations Stratégiques / Métier	9
11.2	Limites et Perspectives	10
	Bibliographie	10
	Bibliography	10

1 Introduction et Contexte Métier



Figure 1: CI Compilation Pipeline

À rédiger par les étudiants : Présentez ici le contexte global de votre projet, la problématique métier que vous cherchez à résoudre, les questions scientifiques soulevées et les opportunités d'aide à la décision sur la base de vos données.

1.1 Contexte du Projet

À rédiger par les étudiants — Pistes de réflexion : - Quels sont les objectifs globaux et le domaine d'étude de votre projet ? - En quoi ce sujet de recherche est-il pertinent et stratégique ? - Pourquoi l'analyse quantitative de ce jeu de données est-elle indispensable pour répondre à votre problématique ?

[Rédiger votre paragraphe de contexte ici]

1.2 Objectif Analytique

À rédiger par les étudiants — Pistes de réflexion : - Quelles sont les variables cibles principales et la tâche globale de modélisation (classification, régression, clustering, etc.) ? - Comment le couplage de données multi-sources et l'intégration de différents types de données (tabulaires, images, signaux, etc.) enrichissent-ils l'analyse ? - Quels sont les livrables analytiques attendus pour répondre à votre problématique et guider les prises de décisions ?

[Rédiger votre paragraphe d'objectifs ici]

2 Acquisition et Préparation des Données (Data Wrangling)

Le succès de tout projet de Data Science repose sur la qualité de la préparation des données [1]. Cette section documente l'audit de qualité et les étapes de nettoyage appliquées à vos jeux de données bruts.

2.1 Audit de Qualité

À rédiger par les étudiants : Présentez un audit critique complet de vos fichiers de données brutes. Indiquez la liste des anomalies physiques et typologiques détectées (formats de dates hétérogènes, outliers physiques, taux de valeurs manquantes, etc.).

[Rédiger votre audit de données ici]

2.2 Algorithme de Nettoyage

À rédiger par les étudiants : Justifiez et détaillez l'enchaînement de vos opérations de traitement (uniformisation des dates, masquage des outliers, imputation, etc.). Faites référence aux fonctions correspondantes de votre module `src/data_clean.py`.

[Rédiger la justification méthodologique ici]

2.3 Travaux Pratiques de Wrangling

3 01 — Acquisition, compréhension et préparation des données

Ce notebook correspond à la première étape du projet : récupérer les données, comprendre leur structure et produire des fichiers propres utilisables pour l'analyse exploratoire, le Machine Learning et le Deep Learning.

Le sujet étudié est la reconnaissance d'activité humaine à partir des capteurs d'un smartphone.

3.1 Objectif du notebook

L'objectif est de préparer le dataset **Human Activity Recognition Using Smartphones**.

Nous allons :

- vérifier la présence des fichiers bruts ;
- charger les labels des activités ;
- charger les noms des variables ;
- reconstruire les jeux de données `train` et `test` ;

- fusionner les données tabulaires avec les labels ;
- sauvegarder des fichiers propres dans `data/processed` ;
- préparer les signaux inertiels pour la partie Deep Learning.

3.2 Structure du dataset

Le dataset contient plusieurs fichiers importants :

- `activity_labels.txt` : correspondance entre identifiant et nom d'activité ;
- `features.txt` : noms des 561 variables numériques ;
- `X_train.txt` et `X_test.txt` : variables numériques déjà préparées ;
- `y_train.txt` et `y_test.txt` : activité associée à chaque ligne ;
- `subject_train.txt` et `subject_test.txt` : identifiant de la personne observée ;
- `Inertial Signals` : signaux temporels utilisés pour le Deep Learning.

3.3 Chargement des activités

Le problème est une classification supervisée avec six activités humaines.

3.4 Chargement des variables

Le dataset tabulaire contient 561 variables numériques extraites des signaux du smartphone.

Certaines variables ont des noms dupliqués. Pour éviter les problèmes dans Pandas, nous rendons les noms de colonnes uniques.

3.5 Reconstruction des jeux train et test

Nous reconstruisons un tableau complet en ajoutant :

- le split `train` ou `test` ;
- l'identifiant du sujet ;
- l'identifiant de l'activité ;
- le libellé de l'activité ;
- les 561 variables numériques.

3.6 Vérifications qualité

Nous vérifions la présence de valeurs manquantes et la cohérence des activités.

3.7 Sauvegarde des données tabulaires propres

Les données propres sont sauvegardées dans `data/processed`.

3.8 Préparation des signaux inertiels

Pour la partie Deep Learning, nous utilisons les signaux temporels présents dans les dossiers `Inertial Signals`.

Chaque observation contient :

- 128 pas de temps ;
- 9 signaux capteurs ;
- une activité associée.

3.9 Conclusion du wrangling

À l'issue de cette étape, nous disposons de deux types de données propres :

1. des données tabulaires pour le Machine Learning classique ;
2. des signaux temporels pour le Deep Learning.

La suite du projet consistera à explorer ces données afin de comprendre la répartition des activités et les différences entre les mouvements.

4 Analyse Exploratoire des Données (EDA)

Dans cette section, nous analysons les relations statistiques fondamentales qui régissent votre domaine d'étude au sein du jeu de données.

4.1 Statistiques Descriptives

À rédiger par les étudiants : Présentez une vue d'ensemble descriptive rapide de vos variables nettoyées.

[Rédiger les statistiques descriptives ici]

4.2 Ingénierie de Variables (Feature Engineering)

À rédiger par les étudiants : Expliquez l'intérêt mathématique et l'impact sur les modèles prédictifs d'extraire des caractéristiques dérivées (ex: variables cycliques temporelles, ratios financiers, ratios physiques, etc.).

[Rédiger votre explication de l'ingénierie de variables ici]

4.3 Travaux Pratiques d'Exploration Visuelle (EDA)

5 ☒ Jalon 1 : Analyse Exploratoire des Données (EDA) & Visualisation (Squelette Étudiant)

Ce notebook est dédié à la découverte de relations clés et à l'analyse visuelle de nos données. À partir du jeu de données propre généré précédemment, nous allons enrichir nos variables explicatives et appeler les fonctions de notre module de visualisation `src.utils_viz` pour générer des graphiques professionnels.

5.0.a 1. Importation des packages et configuration du style

5.0.b 2. Ingénierie de variables temporelles

À faire par l'étudiant : Appliquez la fonction `feature_engineering` de `src.data_clean` pour enrichir votre DataFrame en caractéristiques de temps classiques (heures, jours de la semaine).

5.0.c 3. Visualisations Professionnelles

5.0.c.a A. Profils d'évolution et tendances

À faire par l'étudiant : Appliquez la fonction `plot_generic_trends` de votre module `src.utils_viz` pour tracer l'évolution de la valeur par rapport au temps.

5.0.c.b B. Matrice de corrélation multi-variables

À faire par l'étudiant : Appliquez la fonction `plot_correlation_matrix` de votre module `src.utils_viz` pour calculer et afficher graphiquement la carte thermique des corrélations sur les colonnes `['value', 'hour', 'dayofweek']`.

5.0.c.c C. Nuage de points bivarié

À faire par l'étudiant : Générez un nuage de points de la relation heure vs valeur en colorant les points selon la variable `dayofweek`, en utilisant votre fonction `plot_bivariate_scatter`.

5.0.d 4. Synthèse des observations clés

Sur la base de vos figures, listez les **insights majeurs** observés sur le comportement de vos variables.

6 Visualisation Multidimensionnelle (Insights)

Nous présentons ici les résultats visuels clés permettant de dégager des insights exploitables pour les décideurs, en s'appuyant sur notre module `src/utils_viz.py`.

À rédiger par les étudiants : Présentez et commentez en détail vos 3 à 5 insights majeurs découverts lors de l'exploration descriptive visuelle. Intégrez et justifiez les figures clés générées.

6.1 Profils et Distributions Caractéristiques

```
#| label: fig-distribution-density
#| fig-cap: "Distribution ou profils caractéristiques de vos variables clés."
#| echo: false
# TODO: Utiliser vos fonctions personnalisées de votre module pour tracer la
figure
```

[Commenter la figure et décrire vos observations ici]

6.2 Corrélations Globales

```
#| label: fig-correlation
#| fig-cap: "Matrice de corrélation de Spearman ou de Pearson entre variables."
#| echo: false
# TODO: Utiliser uv.plot_correlation_matrix() de votre module pour tracer la
figure
```

[Commenter la figure et décrire vos observations ici]

7 Modélisation et Apprentissage

7.1 Schéma Global du Pipeline de Données

Le pipeline complet intègre à la fois la branche analytique tabulaire (Machine Learning) et la branche d'analyse visuelle ou de signaux complexes (Deep Learning CNN) :

```
graph TD
    A[Données Brutes Multi-Sources CSV/API] -->|Formatage & Alignement| B(data_clean.clean_dates)
    C[Données Externes Complémentaires] -->|Imputation & Interpolation| D(data_clean.impute_missing_values)
    B & D -->|Gestion Outliers| E[Jeu de données Propre & Fusionné]
    E -->|Extraction Temporelle/Caractéristiques| F[Feature Engineering]
    F -->|Splits Temporels ou Stratifiés| G[Modèle Machine Learning Tabulaire]
    H[Flux Multimédias Réels Images/Signaux] -->|Prétraitement d'images/signaux| I[Réseau Convolutif CNN TensorFlow]
    G -->|Prédictions de la Problématique Métier| J[Livrables & Aide à la Décision]
    I -->|Détection de Motifs Complexes| J

    style E fill:#e0f2fe,stroke:#0284c7,stroke-width:2px
    style J fill:#f0fdf4,stroke:#16a34a,stroke-width:2px
    style G fill:#fef3c7,stroke:#d97706,stroke-width:2px
    style I fill:#fef3c7,stroke:#d97706,stroke-width:2px
```

7.2 Modélisation Tabulaire (Machine Learning)

À rédiger par les étudiants : Expliquez le choix de vos algorithmes d'apprentissage (supervisé ou non supervisé) et décrivez l'importance des variables explicatives.

[Détaillez votre modélisation ici]

7.2.a Travaux Pratiques de Modélisation Tabulaire

8 📌 Jalon 2 : Modélisation Prédictive & Apprentissage (Squelette Étudiant)

Dans ce notebook du **Jalon 2**, l'objectif est d'implémenter un pipeline complet d'apprentissage supervisé pour prédire une variable cible (*value*) à l'aide de Scikit-Learn.

Vous devrez mettre en œuvre une stratégie de découpage train/test chronologique pour respecter la causalité temporelle.

8.0.a 1. Préparation de l'environnement

8.0.b 2. Définition des variables et split chronologique

À faire par l'étudiant : - Identifiez vos colonnes prédictives (`features`) et la colonne cible (`value`). - Séparez chronologiquement vos données en ensembles d'entraînement (`Train`) et de test (`Test`). N'utilisez pas de split aléatoire !

8.0.c 3. Entraînement du modèle de Forêt Aléatoire

À faire par l'étudiant : - Instanciez et entraînez un modèle `RandomForestRegressor`. - Générez les prédictions `y_pred` sur l'ensemble de test.

8.0.d 4. Évaluation métrique

À faire par l'étudiant : Calculez et affichez les scores d'évaluation requis : - **MAE** (Mean Absolute Error) - **RMSE** (Root Mean Squared Error) - **R²** (Coefficient de détermination)

8.0.e 5. Importance des variables explicatives

À faire par l'étudiant : Extrayez et affichez l'importance relative de chaque caractéristique prédictive.

8.1 Modélisation Vision / Deep Learning (Analyse d'Images ou Signaux)

À rédiger par les étudiants : Expliquez l'intérêt de la brique de Deep Learning (images, signaux ou traitement de données structurées complexes) pour classifier ou enrichir vos prédictions. Détaillez l'architecture de votre réseau de neurones convolutif (CNN) conçu sous TensorFlow/Keras (conv, pooling, dense, dropout, activation) et commentez les courbes d'apprentissage obtenues.

[Détaillez votre architecture CNN et analysez ici]

8.1.a Travaux Pratiques de Vision par Ordinateur (CNN)

9 Jalon 2 : Brique de Vision par Ordinateur (CNN & Tensor-Flow) (Squelette Étudiant)

Ce notebook est dédié à la brique d'analyse d'images du **Jalon 2**. L'objectif est de concevoir un Réseau de Neurones Convolutif (CNN) sous TensorFlow/Keras pour classifier des motifs géométriques simples (Classe 0: Cercle vs Classe 1: Multiples Rectangles).

9.0.a 1. Préparation de l'environnement

9.0.b 2. Génération du jeu d'images synthétiques

Pour travailler de manière autonome sans importer de lourdes bases d'images externes, cette fonction utilitaire génère des images simulées en 64×64 pixels de formes simples (Cercle vs Rectangles).

9.0.c 3. Split d'évaluation (Entraînement / Validation)

À faire par l'étudiant : Divisez vos données d'images `X_images` et `y_labels` en 80% pour l'entraînement et 20% pour la validation.

9.0.d 4. Conception de l'architecture du CNN

À faire par l'étudiant : Instanciez un réseau convolutif séquentiel Keras comprenant des couches `Conv2D`, `MaxPooling2D`, `Flatten`, `Dense` et un `Dropout` pour classifier nos deux formes géométriques.

9.0.e 5. Compilation et Entraînement

À faire par l'étudiant : - Compilez le modèle avec l'optimiseur '`adam`' et la fonction de perte binaire. - Entraînez votre CNN sur environ 5 époques.

10 Évaluation Métrique et Validation

10.1 Stratégie de Validation

À rédiger par les étudiants : Expliquez pourquoi le découpage d'évaluation choisi (ex: validation temporelle, stratifiée ou par groupe) est adapté à la structure de vos données pour éviter les fuites de données.

[Rédiger la section de validation ici]

10.2 Résultats et Interprétation

À rédiger par les étudiants : Complétez le tableau d'évaluation ci-dessous en reportant vos résultats de modélisation.

Modèle	Métrique 1 (ex: MAE / Précision)	Métrique 2 (ex: RMSE / F1-Score)	R ² / Score (%)
Baseline (ex: Naïve / Moyenne)	[À compléter]	[À compléter]	[À compléter]
Modèle Choisi	[À compléter]	[À compléter]	[À compléter]

[Interpréter et comparer les métriques d'erreur calculées ici]

11 Data Storytelling et Communication

11.1 Recommandations Stratégiques / Métier

À rédiger par les étudiants : Formulez des recommandations stratégiques, opérationnelles et innovantes basées sur vos découvertes analytiques et prédictives pour guider les décideurs.

[Rédiger vos recommandations ici]

11.2 Limites et Perspectives

À rédiger par les étudiants : Identifiez honnêtement les biais ou limites de votre approche et proposez des pistes d'amélioration futures (ex: intégration de données externes réelles, modélisation plus poussée).

[Rédiger les limites et perspectives ici]

Ce document dynamique a été compilé en Quarto [2].

Bibliographie

Bibliography

- [1] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media, 2020.
- [2] Q. D. Team, “Quarto Dynamic Publishing System: Collaborative Scientific and Technical Publishing.” Accessed: May 18, 2026. [Online]. Available: <https://quarto.org/>