

Mon Projet Data Science

Projet Fil Rouge Data Science - Sujet Libre

Étudiant(e) 1 : [Insérer Prénom] Étudiant(e) 2 : [Insérer Prénom] Étudiant(e) 3 : [Insérer Prénom]
Nom] Nom] Nom]

2026-05-18

Table of contents

1	Introduction et Contexte Métier	2
1.1	Contexte du Projet	3
1.2	Objectif Analytique	3
2	Acquisition et Préparation des Données (Data Wrangling)	3
2.1	Audit de Qualité	3
2.2	Algorithme de Nettoyage	3
2.3	Travaux Pratiques de Wrangling	4
3	01 — Acquisition, compréhension et préparation des données	4
3.1	Objectif du notebook	4
3.2	Structure du dataset	4
3.3	Chargement des activités	4
3.4	Chargement des variables	4
3.5	Reconstruction des jeux train et test	4
3.6	Vérifications qualité	5
3.7	Sauvegarde des données tabulaires propres	5
3.8	Préparation des signaux inertiels	5
3.9	Conclusion du wrangling	5
4	Analyse Exploratoire des Données (EDA)	5
4.1	Statistiques Descriptives	5
4.2	Ingénierie de Variables (Feature Engineering)	5
4.3	Travaux Pratiques d'Exploration Visuelle (EDA)	6
5	02 — Analyse exploratoire et visualisation	6
5.1	Vue générale du dataset	6
5.2	Qualité des données	6
5.3	Répartition des activités	6
5.4	Répartition train/test	6
5.5	Activités par split	6
5.6	Activités dynamiques et statiques	6

5.7	Répartition des sujets	7
5.8	Analyse des variables numériques	7
5.9	Projection PCA	7
5.10	Chargement des signaux inertiels	7
5.11	Exemple de signal par activité	7
5.12	Premiers insights	7
6	Visualisation Multidimensionnelle (Insights)	8
6.1	Profils et Distributions Caractéristiques	8
6.2	Corrélations Globales	8
7	Modélisation et Apprentissage	8
7.1	Schéma Global du Pipeline de Données	8
7.2	Modélisation Tabulaire (Machine Learning)	9
7.2.a	Travaux Pratiques de Modélisation Tabulaire	9
8	 Jalon 2 : Modélisation Prédicative & Apprentissage (Squelette Étudiant)	9
8.0.a	1. Préparation de l'environnement	9
8.0.b	2. Définition des variables et split chronologique	9
8.0.c	3. Entraînement du modèle de Forêt Aléatoire	9
8.0.d	4. Évaluation métrique	9
8.0.e	5. Importance des variables explicatives	9
8.1	Modélisation Vision / Deep Learning (Analyse d'Images ou Signaux)	10
8.1.a	Travaux Pratiques de Vision par Ordinateur (CNN)	10
9	 Jalon 2 : Brique de Vision par Ordinateur (CNN & TensorFlow) (Squelette Étudiant)	10
9.0.a	1. Préparation de l'environnement	10
9.0.b	2. Génération du jeu d'images synthétiques	10
9.0.c	3. Split d'évaluation (Entraînement / Validation)	10
9.0.d	4. Conception de l'architecture du CNN	10
9.0.e	5. Compilation et Entraînement	10
10	Évaluation Métrique et Validation	10
10.1	Stratégie de Validation	10
10.2	Résultats et Interprétation	11
11	Data Storytelling et Communication	11
11.1	Recommandations Stratégiques / Métier	11
11.2	Limites et Perspectives	11
	Bibliographie	11
	Bibliography	11

1 Introduction et Contexte Métier



Figure 1: CI Compilation Pipeline

À rédiger par les étudiants : Présentez ici le contexte global de votre projet, la problématique métier que vous cherchez à résoudre, les questions scientifiques soulevées et les opportunités d'aide à la décision sur la base de vos données.

1.1 Contexte du Projet

À rédiger par les étudiants — Pistes de réflexion : - Quels sont les objectifs globaux et le domaine d'étude de votre projet ? - En quoi ce sujet de recherche est-il pertinent et stratégique ? - Pourquoi l'analyse quantitative de ce jeu de données est-elle indispensable pour répondre à votre problématique ?

[Rédiger votre paragraphe de contexte ici]

1.2 Objectif Analytique

À rédiger par les étudiants — Pistes de réflexion : - Quelles sont les variables cibles principales et la tâche globale de modélisation (classification, régression, clustering, etc.) ? - Comment le couplage de données multi-sources et l'intégration de différents types de données (tabulaires, images, signaux, etc.) enrichissent-ils l'analyse ? - Quels sont les livrables analytiques attendus pour répondre à votre problématique et guider les prises de décisions ?

[Rédiger votre paragraphe d'objectifs ici]

2 Acquisition et Préparation des Données (Data Wrangling)

Le succès de tout projet de Data Science repose sur la qualité de la préparation des données [1]. Cette section documente l'audit de qualité et les étapes de nettoyage appliquées à vos jeux de données bruts.

2.1 Audit de Qualité

À rédiger par les étudiants : Présentez un audit critique complet de vos fichiers de données brutes. Indiquez la liste des anomalies physiques et typologiques détectées (formats de dates hétérogènes, outliers physiques, taux de valeurs manquantes, etc.).

[Rédiger votre audit de données ici]

2.2 Algorithme de Nettoyage

À rédiger par les étudiants : Justifiez et détaillez l'enchaînement de vos opérations de traitement (uniformisation des dates, masquage des outliers, imputation, etc.). Faites référence aux fonctions correspondantes de votre module `src/data_clean.py`.

[Rédiger la justification méthodologique ici]

2.3 Travaux Pratiques de Wrangling

3 01 — Acquisition, compréhension et préparation des données

Ce notebook correspond à la première étape du projet : récupérer les données, comprendre leur structure et produire des fichiers propres utilisables pour l'analyse exploratoire, le Machine Learning et le Deep Learning.

Le sujet étudié est la reconnaissance d'activité humaine à partir des capteurs d'un smartphone.

3.1 Objectif du notebook

L'objectif est de préparer le dataset **Human Activity Recognition Using Smartphones**.

Nous allons :

- vérifier la présence des fichiers bruts ;
- charger les labels des activités ;
- charger les noms des variables ;
- reconstruire les jeux de données `train` et `test` ;
- fusionner les données tabulaires avec les labels ;
- sauvegarder des fichiers propres dans `data/processed` ;
- préparer les signaux inertiels pour la partie Deep Learning.

3.2 Structure du dataset

Le dataset contient plusieurs fichiers importants :

- `activity_labels.txt` : correspondance entre identifiant et nom d'activité ;
- `features.txt` : noms des 561 variables numériques ;
- `X_train.txt` et `X_test.txt` : variables numériques déjà préparées ;
- `y_train.txt` et `y_test.txt` : activité associée à chaque ligne ;
- `subject_train.txt` et `subject_test.txt` : identifiant de la personne observée ;
- `Inertial Signals` : signaux temporels utilisés pour le Deep Learning.

3.3 Chargement des activités

Le problème est une classification supervisée avec six activités humaines.

3.4 Chargement des variables

Le dataset tabulaire contient 561 variables numériques extraites des signaux du smartphone.

Certaines variables ont des noms dupliqués. Pour éviter les problèmes dans Pandas, nous rendons les noms de colonnes uniques.

3.5 Reconstruction des jeux train et test

Nous reconstruisons un tableau complet en ajoutant :

- le split `train` ou `test` ;
- l'identifiant du sujet ;
- l'identifiant de l'activité ;

- le libellé de l'activité ;
- les 561 variables numériques.

3.6 Vérifications qualité

Nous vérifions la présence de valeurs manquantes et la cohérence des activités.

3.7 Sauvegarde des données tabulaires propres

Les données propres sont sauvegardées dans `data/processed`.

3.8 Préparation des signaux inertiels

Pour la partie Deep Learning, nous utilisons les signaux temporels présents dans les dossiers `Inertial Signals`.

Chaque observation contient :

- 128 pas de temps ;
- 9 signaux capteurs ;
- une activité associée.

3.9 Conclusion du wrangling

À l'issue de cette étape, nous disposons de deux types de données propres :

1. des données tabulaires pour le Machine Learning classique ;
2. des signaux temporels pour le Deep Learning.

La suite du projet consistera à explorer ces données afin de comprendre la répartition des activités et les différences entre les mouvements.

4 Analyse Exploratoire des Données (EDA)

Dans cette section, nous analysons les relations statistiques fondamentales qui régissent votre domaine d'étude au sein du jeu de données.

4.1 Statistiques Descriptives

À rédiger par les étudiants : Présentez une vue d'ensemble descriptive rapide de vos variables nettoyées.

[Rédiger les statistiques descriptives ici]

4.2 Ingénierie de Variables (Feature Engineering)

À rédiger par les étudiants : Expliquez l'intérêt mathématique et l'impact sur les modèles prédictifs d'extraire des caractéristiques dérivées (ex: variables cycliques temporelles, ratios financiers, ratios physiques, etc.).

[Rédiger votre explication de l'ingénierie de variables ici]

4.3 Travaux Pratiques d'Exploration Visuelle (EDA)

5 02 — Analyse exploratoire et visualisation

Ce notebook correspond à l'étape d'analyse exploratoire du projet.

L'objectif est de comprendre les données préparées dans le notebook 01 avant de passer à la modélisation.

Nous allons analyser :

- la taille du dataset ;
- la répartition des activités ;
- la séparation train/test ;
- les sujets observés ;
- les différences entre activités dynamiques et statiques ;
- quelques variables numériques ;
- les signaux inertiels utilisés pour la partie Deep Learning.

5.1 Vue générale du dataset

Le dataset contient les observations issues des capteurs du smartphone.

Chaque ligne correspond à une fenêtre temporelle de mouvement associée à une activité humaine.

5.2 Qualité des données

Nous vérifions la présence de valeurs manquantes.

5.3 Répartition des activités

Cette analyse permet de vérifier si certaines activités sont beaucoup plus représentées que d'autres.

Un fort déséquilibre pourrait influencer l'apprentissage des modèles.

5.4 Répartition train/test

Le dataset est déjà séparé en deux parties :

- `train` : données utilisées pour entraîner les modèles ;
- `test` : données utilisées pour évaluer les modèles.

5.5 Activités par split

Nous vérifions que les six activités sont présentes dans les données d'entraînement et dans les données de test.

5.6 Activités dynamiques et statiques

Certaines activités impliquent du mouvement :

- marcher ;
- monter les escaliers ;
- descendre les escaliers.

D'autres sont plutôt statiques :

- assis ;
- debout ;
- allongé.

Cette séparation est importante car les signaux capteurs devraient être très différents entre ces deux groupes.

5.7 Répartition des sujets

Le dataset contient plusieurs sujets. Cette information est importante car les mouvements peuvent varier d'une personne à l'autre.

5.8 Analyse des variables numériques

Le dataset contient 561 variables numériques extraites des signaux du smartphone.

Nous observons ici un résumé statistique d'un échantillon de variables.

5.9 Projection PCA

La PCA permet de réduire les 561 variables en deux dimensions afin de visualiser grossièrement la séparation entre les activités.

Cette visualisation ne sert pas à prédire directement, mais à comprendre si les activités semblent séparables.

5.10 Chargement des signaux inertiels

Pour la partie Deep Learning, nous utiliserons les signaux présents dans les fichiers `.npz`.

Chaque observation contient :

- 128 pas de temps ;
- 9 signaux capteurs.

5.11 Exemple de signal par activité

Nous affichons un exemple du signal `total_acc_x` pour chaque activité.

L'objectif est de visualiser que les mouvements dynamiques produisent des signaux plus variables que les activités statiques.

5.12 Premiers insights

À partir de cette analyse exploratoire, nous pouvons retenir plusieurs points :

1. Le dataset contient six activités humaines clairement identifiées.
2. Les données sont déjà séparées en train et test, ce qui facilitera l'évaluation.
3. Les activités peuvent être regroupées en activités dynamiques et statiques.
4. Les signaux inertiels ont une structure adaptée au Deep Learning : observations, pas de temps, capteurs.
5. La projection PCA donne une première idée de la séparabilité des activités, même si la modélisation sera nécessaire pour mesurer réellement les performances.

La prochaine étape consistera à entraîner des modèles de Machine Learning classiques sur les variables numériques.

6 Visualisation Multidimensionnelle (Insights)

Nous présentons ici les résultats visuels clés permettant de dégager des insights exploitables pour les décideurs, en s'appuyant sur notre module `src/utils_viz.py`.

À rédiger par les étudiants : Présentez et commentez en détail vos 3 à 5 insights majeurs découverts lors de l'exploration descriptive visuelle. Intégrez et justifiez les figures clés générées.

6.1 Profils et Distributions Caractéristiques

```
#| label: fig-distribution-density
#| fig-cap: "Distribution ou profils caractéristiques de vos variables clés."
#| echo: false
# TODO: Utiliser vos fonctions personnalisées de votre module pour tracer la
figure
```

[Commenter la figure et décrire vos observations ici]

6.2 Corrélations Globales

```
#| label: fig-correlation
#| fig-cap: "Matrice de corrélation de Spearman ou de Pearson entre variables."
#| echo: false
# TODO: Utiliser uv.plot_correlation_matrix() de votre module pour tracer la
figure
```

[Commenter la figure et décrire vos observations ici]

7 Modélisation et Apprentissage

7.1 Schéma Global du Pipeline de Données

Le pipeline complet intègre à la fois la branche analytique tabulaire (Machine Learning) et la branche d'analyse visuelle ou de signaux complexes (Deep Learning CNN) :

```
graph TD
    A[Données Brutes Multi-Sources CSV/API] -->|Formatage & Alignement| B(data_clean.clean_dates)
    C[Données Externes Complémentaires] -->|Imputation & Interpolation| D(data_clean.impute_missing_values)
    B & D -->|Gestion Outliers| E[Jeu de données Propre & Fusionné]
    E -->|Extraction Temporelle/Caractéristiques| F[Feature Engineering]
```



```

F -->|Splits Temporels ou Stratifiés| G[Modèle Machine Learning Tabulaire]
H[Flux Multimédias Réels Images/Signaux] -->|Prétraitement d'images/signaux|
I[Réseau Convolutif CNN TensorFlow]
G -->|Prédictions de la Problématique Métier| J[Livrables & Aide à la Décision]
I -->|Détection de Motifs Complexes| J

style E fill:#e0f2fe,stroke:#0284c7,stroke-width:2px
style J fill:#f0fdf4,stroke:#16a34a,stroke-width:2px
style G fill:#fef3c7,stroke:#d97706,stroke-width:2px
style I fill:#fef3c7,stroke:#d97706,stroke-width:2px

```

7.2 Modélisation Tabulaire (Machine Learning)

À rédiger par les étudiants : Expliquez le choix de vos algorithmes d'apprentissage (supervisé ou non supervisé) et décrivez l'importance des variables explicatives.

[Détaillez votre modélisation ici]

7.2.a Travaux Pratiques de Modélisation Tabulaire

8 Jalon 2 : Modélisation Prédictive & Apprentissage (Squelette Étudiant)

Dans ce notebook du **Jalon 2**, l'objectif est d'implémenter un pipeline complet d'apprentissage supervisé pour prédire une variable cible (*value*) à l'aide de Scikit-Learn.

Vous devrez mettre en œuvre une stratégie de découpage train/test chronologique pour respecter la causalité temporelle.

8.0.a 1. Préparation de l'environnement

8.0.b 2. Définition des variables et split chronologique

À faire par l'étudiant : - Identifiez vos colonnes prédictives (*features*) et la colonne cible (*value*). - Séparez chronologiquement vos données en ensembles d'entraînement (*Train*) et de test (*Test*). N'utilisez pas de split aléatoire !

8.0.c 3. Entraînement du modèle de Forêt Aléatoire

À faire par l'étudiant : - Instanciez et entraînez un modèle `RandomForestRegressor`. - Générez les prédictions `y_pred` sur l'ensemble de test.

8.0.d 4. Évaluation métrique

À faire par l'étudiant : Calculez et affichez les scores d'évaluation requis : - **MAE** (Mean Absolute Error) - **RMSE** (Root Mean Squared Error) - **R²** (Coefficient de détermination)

8.0.e 5. Importance des variables explicatives

À faire par l'étudiant : Extrayez et affichez l'importance relative de chaque caractéristique prédictive.

8.1 Modélisation Vision / Deep Learning (Analyse d'Images ou Signaux)

À rédiger par les étudiants : Expliquez l'intérêt de la brique de Deep Learning (images, signaux ou traitement de données structurées complexes) pour classifier ou enrichir vos prédictions. Détaillez l'architecture de votre réseau de neurones convolutif (CNN) conçu sous TensorFlow/Keras (conv, pooling, dense, dropout, activation) et commentez les courbes d'apprentissage obtenues.

[Détaillez votre architecture CNN et analyse ici]

8.1.a Travaux Pratiques de Vision par Ordinateur (CNN)

9 Jalon 2 : Brique de Vision par Ordinateur (CNN & TensorFlow) (Squelette Étudiant)

Ce notebook est dédié à la brique d'analyse d'images du **Jalon 2**. L'objectif est de concevoir un Réseau de Neurones Convolutif (CNN) sous TensorFlow/Keras pour classifier des motifs géométriques simples (Classe 0: Cercle vs Classe 1: Multiples Rectangles).

9.0.a 1. Préparation de l'environnement

9.0.b 2. Génération du jeu d'images synthétiques

Pour travailler de manière autonome sans importer de lourdes bases d'images externes, cette fonction utilitaire génère des images simulées en 64×64 pixels de formes simples (Cercle vs Rectangles).

9.0.c 3. Split d'évaluation (Entraînement / Validation)

À faire par l'étudiant : Divisez vos données d'images `x_images` et `y_labels` en 80% pour l'entraînement et 20% pour la validation.

9.0.d 4. Conception de l'architecture du CNN

À faire par l'étudiant : Instanciez un réseau convolutif séquentiel Keras comprenant des couches `Conv2D`, `MaxPooling2D`, `Flatten`, `Dense` et un `Dropout` pour classifier nos deux formes géométriques.

9.0.e 5. Compilation et Entraînement

À faire par l'étudiant : - Compilez le modèle avec l'optimiseur `'adam'` et la fonction de perte binaire. - Entraînez votre CNN sur environ 5 époques.

10 Évaluation Métrique et Validation

10.1 Stratégie de Validation

À rédiger par les étudiants : Expliquez pourquoi le découpage d'évaluation choisi (ex: validation temporelle, stratifiée ou par groupe) est adapté à la structure de vos données pour éviter les fuites de données.

[Rédiger la section de validation ici]

10.2 Résultats et Interprétation

À rédiger par les étudiants : Complétez le tableau d'évaluation ci-dessous en reportant vos résultats de modélisation.

Modèle	Métrique 1 (ex: MAE / Précision)	Métrique 2 (ex: RMSE / F1-Score)	R ² / Score (%)
Baseline (ex: Naïve / Moyenne)	[À compléter]	[À compléter]	[À compléter]
Modèle Choisi	[À compléter]	[À compléter]	[À compléter]

[Interpréter et comparer les métriques d'erreur calculées ici]

11 Data Storytelling et Communication

11.1 Recommandations Stratégiques / Métier

À rédiger par les étudiants : Formulez des recommandations stratégiques, opérationnelles et innovantes basées sur vos découvertes analytiques et prédictives pour guider les décideurs.

[Rédiger vos recommandations ici]

11.2 Limites et Perspectives

À rédiger par les étudiants : Identifiez honnêtement les biais ou limites de votre approche et proposez des pistes d'amélioration futures (ex: intégration de données externes réelles, modélisation plus poussée).

[Rédiger les limites et perspectives ici]

Ce document dynamique a été compilé en Quarto [2].

Bibliographie

Bibliography

- [1] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media, 2020.
- [2] Q. D. Team, "Quarto Dynamic Publishing System: Collaborative Scientific and Technical Publishing." Accessed: May 18, 2026. [Online]. Available: <https://quarto.org/>